

Modelo CRISP-DM para el Análisis y Prevención del Trabajo Infantil en NNA

Integrantes: Mariana Celis – Yuneidy Gutierrez
– Josue Pedraza


Objetivos

Caracterizar y segmentar la población de NNA mediante análisis multivariado para identificar perfiles que permitan mejorar la efectividad y focalización de intervenciones.

Desarrollar un proceso de análisis estadístico siguiendo la metodología CRISP-DM , que permita:

- 01 • Evaluar la calidad, estructura y completitud de la información.
- 02 • Preparar y transformar datos para análisis multivariado asegurando consistencia
- 03 • Identificar perfiles distintos mediante Análisis de Correspondencias Múltiples (MCA) y clustering
- 04 • Interpretar y validar perfiles con características significativas
- 05 • Generar recomendaciones estratégicas específicas por perfil
- 06 • Establecer sistema de monitoreo continuo con KPIs

Metodología CRISP-DM



1. Entendimiento del Negocio



- El conjunto de datos corresponde a registros administrativos de atención a niños, niñas y adolescentes (NNA) en procesos de prevención y erradicación del trabajo infantil .
- El propósito institucional de estos registros es comprender los patrones y características de la población atendida, con el fin de orientar decisiones sobre focalización, seguimiento y evaluación de resultados .
- Desde un enfoque estadístico, el proyecto busca caracterizar e identificar grupos homogéneos dentro de la base de datos a partir de variables sociodemográficas, territoriales y de intervención, utilizando técnicas exploratorias y de clustering no supervisado .

01

02


03

2. Entendimiento de los datos

Fuente de Datos

El análisis se desarrolla a partir del archivo **base_datos_completa_NNA_TI_anon.xlsx**, el cual contiene dos hojas principales:

- variables→ Diccionario con los nombres, descripción y codificación de las variables disponibles.
- BD→ Base de datos principales con los registros de niños, niñas y adolescentes vinculados a programas de intervención.




2. Entendimiento de los datos

Descripción General



56.473 registros, 115 variables



Información Sociodemográfica

Información Territorial



Información de fechas y seguimiento



2. Entendimiento de los datos

Calidad de Datos



104 variables con información faltante

Top 15 variables con más valores 99999:

- Sub-Sección => INFORMACIÓN DEL MENOR NNA IDENTIFICADO COMO TRABAJADOR: 56,473 (100.0%)
- Sub-Sección => INFORMACIÓN DEL ACUDIENTE: 56,473 (100.0%)
- ÚLTIMA INTERVENCIÓN: 56,473 (100.0%)
- DIRECCIÓN DE LA VIVIENDA: 56,473 (100.0%)
- ACOMPAÑAMIENTO 4: 56,473 (100.0%)
- ACOMPAÑAMIENTO 3: 56,473 (100.0%)
- ACOMPAÑAMIENTO 2: 56,473 (100.0%)
- Sub-Sección => INFORMACIÓN LABORAL: 56,473 (100.0%)
- Sub-Sección => RESULTADOS DE LA REPOSICION: 56,473 (100.0%)
- Sub-Sección => Intervención de Niño, Niña o Adolescente: 56,473 (100.0%)
- Sub-Sección => RESULTADOS DE LA INTERVENCIÓN: 56,473 (100.0%)
- CORREO 2: 56,468 (100.0%)
- VEREDA: 56,467 (100.0%)
- RazonAbandonoEscolar: 56,466 (100.0%)
- ESPECIAL: 56,441 (99.9%)

3. Procesamiento de datos: Discretización de variables

```
=====
---DISCRETIZACIÓN DE VARIABLES NUMÉRICAS---
=====
```

```
Discretizando EDAD → EDAD_GRUPO
```

```
✓ EDAD_GRUPO creada
```

```
Distribución:
```

```
EDAD_GRUPO
```

0-5_Primeria_Infancia	8407
11-14_Preadolescencia	8147
15-18_Adolescencia	4445
6-10_Infancia	10746
nan	24728

```
Name: count, dtype: int64
```

```
Discretizando UPZ/UPR → UPZ_DENSIDAD
```

```
✓ UPZ_DENSIDAD creada
```

```
Distribución:
```

```
UPZ_DENSIDAD
```

UPZ_Media_Alta	12449
UPZ_Baja_Densidad	11790
UPZ_Media_Baja	11772
UPZ_Alta_Densidad	10810
nan	9652

```
Name: count, dtype: int64
```

```
Calculando FASE_PROGRAMA desde Fecha_intervencion
```

```
✓ FASE_PROGRAMA creada
```

```
Distribución:
```

```
FASE_PROGRAMA
```

Fase_Prolongada_mas2a	38062
Fase_Seguimiento_6m-2a	18411

```
Name: count, dtype: int64
```

```
📊 Total de variables categóricas nuevas: 3
```


3. Procesamiento de Datos



reemplazo NA

Se hizo un reemplazo de valores nan none NaN NA por valores NO REPORTA



Limpieza

Limpieza de espacios y estandarizacion



Cardinalidad

Analaisis de cardinalidad: Alta cardinalidad representa problematicas para MCA

Criterios de exito

Criterios de Éxito

Criterios Técnicos

Criterio	Métrica	Meta	Resultado
Varianza explicada	Inercia acumulada 5 dims	$\geq 50\%$	68.2% - CUMPLIDO
Calidad clustering	Silhouette Score	> 0.5	0.559 - CUMPLIDO
Separación clusters	Davies-Bouldin Index	< 1.0	0.773 - CUMPLIDO
Tamaño mínimo por perfil	N registros	$\geq 1,000$	Todos cumplen - CUMPLIDO
Diferenciación	Chi-Square p-value	< 0.05	Cumplido - CUMPLIDO
Reproducibilidad	Random state	Determinístico	Implementado - CUMPLIDO

Resultado Final: Todos los criterios técnicos alcanzados exitosamente

4. Modelamiento de Datos

Variables Disponibles para el modelamiento:

✓ Datos cargados exitosamente

- Dataset: 56,473 registros × 21 variables
- Variables categóricas: 21

📋 Variables disponibles:

1. SEXO	(4 categorías)
2. ESTRATO	(5 categorías)
3. Localidad_fic	(17 categorías)
4. TIPO INTERVENCIÓN	(5 categorías)
5. NACIONALIDAD	(4 categorías)
6. ESTADO CIVIL	(3 categorías)
7. ETNIA	(2 categorías)
8. POBLACIÓN DIFERENCIAL Y DE INCLUSIÓN	(3 categorías)
9. OCUPACIÓN	(6 categorías)
10. CATEGORÍAS DE LA DISCAPACIDAD	(2 categorías)
11. VÍNCULO CON EL JEFE DE HOGAR	(4 categorías)
12. ZONA	(3 categorías)
13. BARRIO PRIORIZADO	(5 categorías)
14. MANZANA DEL CUIDADO	(5 categorías)
15. AFILIACIÓN AL SGSSS.1	(5 categorías)
16. ¿EN DONDE REALIZA PRINCIPALMENTE SU TRABAJO?	(5 categorías)
17. INTERVENCIÓN DE NIÑO, NIÑA O ADOLESCENTE QUE TERMINA EL PROCESO	(5 categorías)
18. NNA DESVINCULADO DE LA ACTIVIDAD LABORAL	(5 categorías)
19. EDAD_GRUPO	(5 categorías)
20. UPZ_DENSIDAD	(5 categorías)
21. FASE_PROGRAMA	(2 categorías)

Matriz de asociación de Cramer

***Hallazgos importantes
(mencionar 2-3):***


> "Encontramos asociaciones fuertes (>0.5) entre:"

**- *BARRIO PRIORIZADO ↔
MANZANA DEL CUIDADO:* V=0.87
(casi perfectamente relacionadas)**

- *NACIONALIDAD ↔ AFILIACIÓN
SGSSS:* V=0.68 (los venezolanos
tienen patrones distintos de
afiliación)

- *ZONA ↔ UPZ_DENSIDAD:*
V=0.70 (lógico, son variables geográficas relacionadas)

> "Esto nos dice que hay estructura en los datos, justificando el uso de MCA."





4. Modelamiento de Datos

APLICACIÓN DEL MCA

```
=====
🎯 ANÁLISIS DE CORRESPONDENCIAS MÚLTIPLES (MCA)
=====
```

- 1 Preparando datos para MCA...
 - ✓ 21 variables convertidas a tipo 'category'
- 2 Ejecutando MCA...
 - Extrayendo 10 componentes principales...
 - ✓ MCA ejecutado exitosamente
- 3 Transformando datos al espacio factorial...
 - ✓ Coordenadas de individuos: (56473, 10)

4. Modelamiento de Datos: Análisis de Inercia y Varianza Explicada



Valores propios y varianza explicada:



Dim	Eigenvalue	Inercia %	Acumulada %
Dim1	0.3785	25.70	25.70
Dim2	0.2208	14.99	40.69
Dim3	0.2004	13.61	54.30
Dim4	0.1332	9.04	63.34
Dim5	0.1053	7.15	70.49
Dim6	0.0988	6.71	77.20
Dim7	0.0929	6.30	83.50
Dim8	0.0854	5.80	89.30
Dim9	0.0800	5.43	94.73
Dim10	0.0776	5.27	100.00

Criterios para selección de dimensiones:


- Criterio del codo: Observar gráfico de sedimentación
- Criterio de Kaiser (eigenvalue > promedio): 10 dimensiones
- Criterio del 80% de inercia: 7 dimensiones

✓ DIMENSIONES RECOMENDADAS: 5

4. Modelamiento de Datos: Mapas Factoriales Por Dimensión



4. Modelamiento de Datos: Mapas Factoriales Por Dimensión



4. Modelamiento de Datos: Análisis Cluster

1 Determinando número óptimo de clusters...

Probando de 2 a 10 clusters...




k=2: Silhouette=0.377, Davies-Bouldin=1.288

k=4: Silhouette=0.559, Davies-Bouldin=0.711

k=6: Silhouette=0.503, Davies-Bouldin=0.732

k=8: Silhouette=0.416, Davies-Bouldin=0.923

k=10: Silhouette=0.413, Davies-Bouldin=0.975



✓ Número óptimo de clusters (Silhouette): k = 4

4. Modelamiento de Datos: Análisis Cluster




4. Modelamiento de Datos: Perfil de cada Cluster

=====	=====	=====	=====
PERFIL 1 (n=23,672 NNA, 41.9%)	PERFIL 2 (n=20,065 NNA, 35.5%)	PERFIL 3 (n=4,661 NNA, 8.3%)	PERFIL 4 (n=8,075 NNA, 14.3%)
=====	=====	=====	=====
✦ SEXO: • 1- Hombre: 51.1% • 2- Mujer: 48.9% ✦ EDAD_GRUPO: • 6-10_Infancia: 34.1% • 0-5_Primer_Infancia: 27.1% • 11-14_Preadolescencia: 25.5% ✦ ESTRATO: • 2. Bajo: 65.0% • 3. Medio-bajo: 18.7% • 1. Bajo-bajo: 16.2% ✦ NACIONALIDAD: • Colombia: 82.3% • Venezuela (Bolivarian Republic of): 17.6% • Otros_NACIONALIDAD: 0.1% ✦ NNA DESVINCULADO DE LA ACTIVIDAD LABORAL: • SI: 77.3% • NO: 19.1% • No_reporta: 3.6%	✦ SEXO: • No_reporta: 55.7% • 1- Hombre: 22.3% • 2- Mujer: 22.1% ✦ EDAD_GRUPO: • No_reporta: 100.0% ✦ ESTRATO: • No_reporta: 100.0% ✦ NACIONALIDAD: • No_reporta: 55.7% • Colombia: 36.9% • Venezuela (Bolivarian Republic of): 7.3% ✦ NNA DESVINCULADO DE LA ACTIVIDAD LABORAL: • SI: 83.6% • NO: 13.6% • No_reporta: 2.7%	✦ SEXO: • 1- Hombre: 50.1% • 2- Mujer: 49.9% ✦ EDAD_GRUPO: • No_reporta: 100.0% ✦ ESTRATO: • 2. Bajo: 61.4% • 3. Medio-bajo: 21.2% • 1. Bajo-bajo: 17.1% ✦ NACIONALIDAD: • Colombia: 83.8% • Venezuela (Bolivarian Republic of): 16.0% • Otros_NACIONALIDAD: 0.2% ✦ NNA DESVINCULADO DE LA ACTIVIDAD LABORAL: • No_reporta: 57.6% • Si: 33.4% • Otros_NNA DESVINCULADO DE : 9.0%	✦ SEXO: • 1- Hombre: 50.3% • 2- Mujer: 49.7% • No_reporta: 0.0% ✦ EDAD_GRUPO: • 6-10_Infancia: 33.0% • 11-14_Preadolescencia: 26.1% • 0-5_Primer_Infancia: 24.5% ✦ ESTRATO: • No_reporta: 100.0% ✦ NACIONALIDAD: • Colombia: 83.5% • Venezuela (Bolivarian Republic of): 16.3% • Otros_NACIONALIDAD: 0.1% ✦ NNA DESVINCULADO DE LA ACTIVIDAD LABORAL: • No_reporta: 100.0%

5. EVALUACION: Panel de Indicadores de desempeño

Panel de Indicadores Clave de Desempeño (KPIs)



5. EVALUACION: validación del modelo

✓ VALIDACIÓN DEL MODELO MCA

1 VALIDACIÓN ESTADÍSTICA:

- Inercia explicada (5 dims): 70.49%
- Coeficiente de Silueta: 0.559 (buena separación)
- Índice Davies-Bouldin: 0.773 (clusters bien definidos)

✓ El modelo tiene buena calidad estadística

2 VALIDACIÓN DE INTERPRETABILIDAD:

- 4 perfiles claramente diferenciados
- Cada perfil tiene características distintivas
- Perfiles alineados con problemáticas reales del programa

✓ Los perfiles son interpretables y accionables

3 VALIDACIÓN DE UTILIDAD:

- Identificación clara de grupos prioritarios (P2 y P3)
- Modelo de referencia identificado (P1)
- Recomendaciones específicas por perfil
- KPIs definidos para monitoreo continuo

✓ El modelo genera valor para la toma de decisiones

5. EVALUACION: Factores de riesgo

IDENTIFICACIÓN DE FACTORES DE RIESGO

Casos con resultado documentado: 42,319
Desvinculados: 35,071 (82.9%)

Tasa de desvinculación por factor:

SEXO:

	Tasa_Éxito_%	N
SEXO		
2- Mujer	82.0	15473
1- Hombre	81.4	16033

Grupos con menor tasa de éxito (< 81.7%):

- 1- Hombre: 81.4% (n=16,033)

EDAD_GRUPO:

	Tasa_Éxito_%	N
EDAD_GRUPO		
11-14_Preadolescencia	83.2	5819
6-10_Infancia	81.8	7804
0-5_Primer Infancia	78.2	6173
15-18_Adolescencia	74.5	3013

Grupos con menor tasa de éxito (< 80.2%):

- 0-5_Primer Infancia: 78.2% (n=6,173)
- 15-18_Adolescencia: 74.5% (n=3,013)

ESTRATO:

	Tasa_Éxito_%	N
ESTRATO		
Otros_ESTRATO	92.3	13
3. Medio-bajo	81.7	4300
2. Bajo	80.3	14776
1. Bajo-bajo	78.1	3719

Grupos con menor tasa de éxito (< 80.2%):

- 1. Bajo-bajo: 78.1% (n=3,719)

NACIONALIDAD:

	Tasa_Éxito_%	N
NACIONALIDAD		
Venezuela (Bolivarian Republic of)	84.8	5428
Colombia	81.0	26026
Otros_NACIONALIDAD	80.8	52

Grupos con menor tasa de éxito (< 81.7%):

- Colombia: 81.0% (n=26,026)
- Otros_NACIONALIDAD: 80.8% (n=52)

ZONA:

	Tasa_Éxito_%	N
ZONA		
Otros_ZONA	82.4	17
1- Urbana	82.3	40772

Grupos con menor tasa de éxito (< 82.3%):

- 1- Urbana: 82.3% (n=40,772)



GRACIAS